

Estimativa do Índice Glicêmico de Bebidas Comerciais Usando Processamento de Imagens com Deep Learning para Monitoramento de Saúde

Lorrany B. Amorim Marim¹

*Departamento de Ciência da Computação
Universidade Federal de Ouro Preto
Ouro Preto, MG, Brasil
lorrany.marim@ufop.aluno.edu.br*

André Luiz Carvalho Ottoni²

*Departamento de Ciência da Computação
Universidade Federal de Ouro Preto
Ouro Preto, MG, Brasil
andre.ottoni@ufop.edu.br*

Abstract—The monitoring and control of blood glucose levels are crucial for individuals with metabolic diseases, such as diabetes (type 1, type 2, and gestational) and insulin resistance. This research addresses a gap in available tools for glycemic management, particularly concerning commercial beverages that are widely consumed and can significantly impact glycemic control. The study proposes an artificial intelligence (AI)-based solution using deep learning techniques to estimate the glycemic index (GI) of ready-to-drink commercial beverages through image processing. By utilizing convolutional neural networks (CNNs) and other deep learning architectures, the proposed system aims to classify and estimate the glycemic impact of various beverages to aid consumers in managing their blood glucose levels effectively. Recent studies have shown promising results in using deep learning models, including bidirectional recurrent neural networks (RNNs) with attention mechanisms, for reliable glucose predictions. The developed model is designed to recognize beverage images, estimate GI, and categorize them as suitable, recommended with caution, or unsuitable for glycemic control, enhancing accessibility and promoting informed dietary choices for individuals with diabetes and insulin resistance. This study discusses the economic and health relevance of GI in food and beverages, the challenges of accurately estimating GI in liquid matrices, and the potential of AI for real-time applications on mobile devices.

Index Terms—Artificial intelligence, glycemic index, diabetes, insulin resistance, blood glucose monitoring, deep learning, convolutional neural networks, image processing, glycemic control, recurrent neural networks, commercial beverages, mobile applications, metabolic diseases.

I. INTRODUÇÃO

Este estudo visa abordar o desenvolvimento de ferramentas práticas para indivíduos que precisam monitorar os níveis de glicose (açúcar) no sangue, como pessoas com diabetes e resistência insulínica (pré-diabéticos). O projeto propõe o uso de inteligência artificial para o reconhecimento de bebidas comerciais prontas para consumo, vendidas em supermercados, lojas de conveniência e restaurantes. Através do reconhecimento por imagem, calcula-se o impacto glicêmico dessas bebidas, classificando-as como adequadas, consumíveis com recomendações, ou inadequadas.

O controle e monitoramento dos níveis de glicemia no sangue são fundamentais para indivíduos com doenças metabólicas, como o diabetes (tipos 1, 2 e gestacional) e a resistência insulínica. Essas condições, caracterizadas pela produção excessiva de glicose (hiperglicemia) ou pela insuficiência na produção desse açúcar (hipoglicemia), afetam diretamente a saúde, podendo resultar em complicações graves, como retinopatia, nefropatia, infarto do miocárdio, neuropatias e até a morte, se não forem adequadamente controladas [1].

Estudos clínicos como o Diabetes Control and Complications Trial (DCCT) e o United Kingdom Prospective Diabetes Study (UKPDS) forneceram evidências robustas sobre a importância do controle intensivo da glicemia em pacientes com diabetes tipo 1 e tipo 2, mostrando uma redução significativa nas complicações microvasculares e macrovasculares associadas à doença [1]. Adicionalmente, o Diabetes Prevention Program (DPP) demonstrou que mudanças no estilo de vida, combinadas ao controle glicêmico, podem retardar a progressão da resistência insulínica para o diabetes tipo 2 e reduzir o risco de complicações cardiovasculares [2].

Diante do aumento global dos casos de diabetes, que afeta 8,5% da população adulta e foi responsável por 1,5 milhão de mortes em 2019 [3], é imperativo buscar novas ferramentas para auxiliar o controle glicêmico. Uma dessas ferramentas é o índice glicêmico (IG), que classifica os alimentos de acordo com a rapidez com que elevam os níveis de glicose no sangue. Alimentos com baixo IG são absorvidos de forma mais lenta, o que ajuda a manter os níveis de glicose estáveis, sendo essa uma estratégia essencial para o controle da glicemia em pacientes com diabetes e resistência insulínica. Alimentos com IG médio produzem uma elevação moderada nos níveis de glicose, enquanto alimentos com IG alto são absorvidos rapidamente, o que pode levar a picos de glicose no sangue, sendo desaconselhados para pessoas que precisam controlar rigorosamente a glicemia [4], [5].

A aplicação prática do índice glicêmico (IG), apesar de ser amplamente reconhecido como uma ferramenta essencial para

o controle glicêmico, enfrenta desafios significativos [6]. Esse problema é particularmente notável no caso de bebidas comerciais, tanto alcoólicas quanto não alcoólicas, amplamente consumidas globalmente. Muitas dessas bebidas apresentam altos índices glicêmicos devido à sua composição nutricional, o que pode levar a elevações rápidas nos níveis de glicose no sangue, complicando o manejo de condições como o diabetes. Além disso, as tabelas nutricionais comumente disponíveis não incluem o IG dos produtos, o que obriga os consumidores a estimarem o impacto glicêmico com base em informações limitadas, como o teor de carboidratos e açúcares [6].

A escolha do estudo sobre predição de valores glicêmicos em bebidas comerciais justifica-se pela relevância econômica e social desse setor. Em 2024, o mercado global de bebidas não alcoólicas gerou uma receita de aproximadamente US\$1,61 trilhão, enquanto o setor de bebidas alcoólicas alcançou cerca de US\$1,667 bilhões [7], [8]. Esses valores refletem a alta demanda por bebidas comerciais e a necessidade de ferramentas precisas para auxiliar o consumidor na compreensão dos impactos glicêmicos desses produtos, especialmente para aqueles que necessitam monitorar a glicemia regularmente.

Samir et al. [?] propõe dispositivos para monitoramento de IG de alimentos por imagem e atividades físicas, em outro estudo Afnan Ahmed Crystal et al. [?] discute a integração de sistemas de reconhecimento de alimentos por imagem (FIRS) com redes neurais convolucionais

Para enfrentar essa lacuna, propomos uma solução baseada em inteligência artificial (IA), utilizando redes neurais artificiais e aprendizado profundo [16]. Estudos recentes indicam que a aplicação de IA na predição de índices glicêmicos tem mostrado resultados promissores, com o uso de modelos de classificação de imagens alimentares para identificar categorias de índice glicêmico (IG) de forma automatizada [9]. Essa tecnologia, ao reconhecer e classificar imagens capturadas por dispositivos móveis, como smartphones, em tempo real, poderia consultar uma base de dados previamente treinada para estimar o IG das bebidas analisadas [17]. O sistema proposto forneceria, assim, uma ferramenta prática para os consumidores classificarem a adequação de uma bebida para consumo, com base na estimativa do IG, contribuindo para o controle glicêmico e a prevenção de complicações associadas ao diabetes, por meio de uma análise de IG prática e acessível para bebidas comerciais.

II. REFERENCIAL TEÓRICO

A. Controle Glicêmico e Impacto na Saúde de Pacientes Diabéticos e Resistência Insulínica

A insulina, hormônio essencial produzido pelo pâncreas, é responsável por facilitar a entrada de glicose nas células musculares, hepáticas e adiposas, onde é utilizada como fonte de energia. Esse suprimento de glicose é proveniente da alimentação e também sintetizado pelo fígado em situações de demanda, como o jejum. Após as refeições, o aumento dos níveis de glicose no sangue estimula a liberação de insulina,

regulando a glicemia e mantendo-a dentro de níveis saudáveis [20].

A resistência insulínica, caracterizada pela resposta ineficiente das células à insulina, é um importante fator de risco para o desenvolvimento do diabetes tipo 2. Segundo o National Institute of Diabetes and Digestive and Kidney Diseases (NIDDK), cerca de 50% dos indivíduos com pré-diabetes, que frequentemente apresentam resistência insulínica, podem evoluir para o diabetes tipo 2 se não houver intervenção [20]. A resistência prolongada pode levar ao esgotamento das células beta pancreáticas, reduzindo a produção de insulina e agravando a hiperglicemia [21]. Já o diabetes tipo 1 é marcado pela destruição autoimune das células beta, resultando em uma produção mínima ou nula de insulina e em hiperglicemia persistente, caracterizando essa forma da doença [22].

O controle glicêmico é fundamental tanto para o tratamento do diabetes quanto para a prevenção de complicações como doenças cardiovasculares e neuropatias [1], [12]. Em pacientes com resistência à insulina, mudanças no estilo de vida — incluindo dieta com baixo índice glicêmico e aumento da atividade física — são recomendadas para minimizar a progressão para o diabetes tipo 2 [11], [5]. Para diabéticos, o controle glicêmico adequado reduz o risco de complicações micro e macrovasculares, beneficiando tanto pacientes com diabetes tipo 1 quanto tipo 2 [1], [12], [13].

B. Pesquisas e Estudos do Impacto na Saúde Através do Controle Glicêmico

Em 2024, o Songyuan Community Health Center, na China, acompanhou 359 pacientes com diabetes tipo 2 por seis meses, monitorando o controle glicêmico através de registros e exames periódicos. O estudo demonstrou que 62,7% dos pacientes alcançaram índices glicêmicos mais estáveis, atribuídos a intervenções alimentares e ao ajuste de medicamentos, com efeitos positivos nos resultados clínicos [10].

Estudos históricos, como o Diabetes Control and Complications Trial (DCCT) e o Epidemiology of Diabetes Interventions and Complications (EDIC), liderados pelo NIDDK, mostraram que o controle intensivo da glicemia reduz significativamente as complicações microvasculares (retinopatia, nefropatia e neuropatia). A persistência dos efeitos do controle intensivo, mesmo após a normalização dos níveis de HbA1c, estabeleceu o conceito de "memória metabólica". Além disso, o EDIC observou uma redução de 58% em eventos cardiovasculares graves entre os pacientes com diabetes tipo 1 submetidos à terapia intensiva [12].

De forma semelhante, o UK Prospective Diabetes Study (UKPDS) avaliou o controle glicêmico em pacientes com diabetes tipo 2, demonstrando que a redução nos níveis de HbA1c diminuiu em 25% as complicações microvasculares, embora os efeitos sobre complicações cardiovasculares fossem menos expressivos. No entanto, o conceito de "memória metabólica" observado no DCCT foi reforçado no UKPDS, sugerindo benefícios cardiovasculares com o controle prolongado [14].

Outros estudos, como o Action to Control Cardiovascular Risk in Dia- betes (ACCORD), apoiado por instituições americanas como o National Heart, Lung, and Blood Institute (NHLBI) e o Centers for Disease Control and Prevention (CDC), examinaram a eficácia do controle intensivo da glicemia em pacientes com diabetes tipo 2 de alto risco cardiovascular. O estudo concluiu que, para esse perfil, o controle padrão de HbA1c entre 7,0% e 7,9% foi mais seguro que um controle intensivo, sugerindo que o monitoramento contínuo pode ser uma estratégia mais apropriada para reduzir a mortalidade [18].

Por fim, o Veterans Affairs Diabetes Trial (VADT) investigou a relação entre aterosclerose e controle intensivo da glicemia em pacientes com diabetes tipo 2. A pesquisa revelou que o controle intensivo foi mais eficaz na redução de eventos cardiovasculares entre pacientes com baixo índice de cálcio coronariano, enquanto os pacientes com aterosclerose avançada mostraram menor benefício, destacando a necessidade de individualização do tratamento [19].

Esses estudos, juntamente com o Finnish Diabetes Prevention Study (DPS), que observou uma redução de 58% no risco de diabetes tipo 2 com intervenções no estilo de vida, ressaltam a importância de estratégias preventivas e de controle intensivo baseadas em características específicas dos pacientes [23].

Portanto, estudos sugerem que dietas de baixo índice glicêmico (IG) podem reduzir significativamente os riscos associados ao diabetes e a doenças cardiovasculares, conforme discutido anteriormente. As evidências indicam que essas dietas melhoram o controle glicêmico em comparação com dietas de alto IG, proporcionando benefícios como a redução dos níveis de HbA1c e proteínas glicadas, o que resulta em uma melhora expressiva na glicemia média em pacientes com diabetes tipo 1 e tipo 2. Além disso, uma dieta de baixo IG pode ter efeitos clínicos semelhantes aos de alguns agentes farmacológicos destinados ao controle da hiperglicemia pós-prandial, posicionando-se como uma estratégia eficaz para a gestão do diabetes [37].

Em um estudo de Jenkins et al. sobre os efeitos metabólicos de uma dieta de baixo IG, foi observado que o consumo de alimentos e bebidas de baixo IG resultou em uma redução significativa na glicose ao longo de 12 horas, em comparação com dietas de alto IG. Além disso, houve uma diminuição na proteína sérica glicada (frutossamina), indicando uma redução nos níveis médios de glicose no sangue nas últimas 1 a 3 semanas, o que sugere uma melhora no controle glicêmico. Observou-se também uma redução de 32% na secreção de insulina e uma diminuição de 15% no colesterol total. [38].

Outro estudo realizado por Brand-Miller e Buyken (2012) apontou para a redução dos riscos cardiovasculares associados a dietas de baixo IG, em comparação com dietas de alto IG. Esses achados indicam uma melhora no controle de peso em pessoas com sobrepeso, condição frequentemente associada à resistência insulínica, auxiliando na prevenção da recuperação

de peso após a perda inicial. Dietas de baixo IG também foram associadas à melhora em marcadores inflamatórios e à redução de doenças inflamatórias não cardiovasculares e não oncológicas. [39].

Para aproveitar os benefícios das dietas de baixo IG, indivíduos que necessitam de controle glicêmico devido a condições de saúde devem considerar tanto alimentos sólidos quanto líquidos. Embora a maioria dos estudos e orientações sobre IG concentre-se em alimentos sólidos, é essencial conhecer o IG das bebidas comercializadas, uma vez que elas representam uma parte significativa do consumo total diário de carboidratos.

C. Importância do Índice Glicêmico (IG) para o Controle Glicêmico

O índice glicêmico (IG) é uma medida que classifica os alimentos contendo carboidratos de acordo com seu impacto na glicemia pós-prandial, comparando a resposta glicêmica com uma referência, geralmente glicose pura ou pão branco [4], [27]. Os carboidratos são o principal macronutriente influente no IG devido à sua absorção rápida e direta, que eleva os níveis de glicose no sangue. Alimentos de alto IG causam aumentos rápidos na glicemia, enquanto alimentos de baixo IG promovem elevações mais lentas e moderadas [24], [5].

Essa classificação é especialmente relevante para indivíduos com diabetes e resistência insulínica, nos quais a ingestão de carboidratos de alto IG pode exacerbar o descontrole glicêmico, exigindo ajustes na administração de insulina e dificultando o controle da doença [25], [26]. Para esses indivíduos, o consumo de alimentos de baixo IG pode ajudar a reduzir variações glicêmicas, melhorando a sensibilidade à insulina e contribuindo para um manejo dietético mais seguro.

Os alimentos são classificados segundo seus valores de índice glicêmico (IG) em três categorias: baixo (≤ 55), médio (56-69) e alto (≥ 70) [4], [27]. Esses valores são estabelecidos pela medição da área sob a curva glicêmica (AUC) nas duas horas subsequentes à ingestão de uma porção padrão de 50 gramas de carboidratos disponíveis. Esse método fornece uma base para identificar alimentos que causam menor impacto nos níveis de glicose. A fórmula do IG foi originalmente proposta por Jenkins et al., que calcularam o IG como a razão entre a AUC do alimento teste e a AUC de um alimento de referência (geralmente glicose pura), multiplicada por 100, conforme a seguinte fórmula:

$$IG = \left(\frac{\text{AUC do alimento teste}}{\text{AUC do alimento referência}} \right) \times 100$$

como mostrado em [4].

Essa abordagem fornece uma referência para identificar alimentos com menor impacto glicêmico, essencial para o controle dietético em condições de controle glicêmico como o diabetes [4].

Diversos fatores podem influenciar o IG, como a composição do alimento (tipo de carboidrato, presença de fibras e

proteínas), o método de preparo e a estrutura física, sendo que alimentos processados tendem a ter IG mais alto [28].

Segundo Jenkins e Brand-Miller, o uso do IG como ferramenta no controle glicêmico é uma estratégia eficaz e prática, especialmente para pacientes com diabetes e resistência insulínica, pois permite a escolha de alimentos que minimizam as flutuações glicêmicas, promovendo um controle metabólico mais estável [4], [27], [28].

D. Definição nos Desafios na Predição do IG em Bebidas Comerciais

O mercado global de bebidas alcoólicas e não alcoólicas ocupa uma fatia significativa do consumo, evidenciando-se pela estimativa de um consumo médio per capita de 28,22 litros para bebidas alcoólicas e 105,70 litros para bebidas não alcoólicas em 2024, com uma receita combinada de US\$3,77 trilhões [7], [8]. Apesar de seu impacto econômico e presença difundida, há limitações quanto à acessibilidade de dados nutricionais detalhados, especialmente informações sobre o índice glicêmico (IG). O consumidor final frequentemente subestima a quantidade de carboidratos presentes em bebidas, associando-os mais a alimentos sólidos, como pães e massas, do que a bebidas como refrigerantes, sucos, bebidas energéticas e alcoólicas fermentadas (cervejas e saquês) [6]. Essas limitações nutricionais dificultam o controle glicêmico, particularmente para indivíduos com necessidades específicas, como diabéticos e pessoas com resistência insulínica, que precisam monitorar o impacto glicêmico dos produtos consumidos. A complexidade na análise do IG em bebidas é reforçada por estudos que demonstram a variabilidade na composição de carboidratos em líquidos, o que exige metodologias avançadas, como a cromatografia líquida de alta performance (HPLC) e a eletroforese capilar, para identificar e quantificar precisamente os tipos de açúcares presentes [29]. Embora tais técnicas permitam a detecção precisa de carboidratos, elas não são viáveis para uso em larga escala ou acessíveis ao consumidor final. Além disso, métodos baseados na composição de macronutrientes, conforme descrito em estudos recentes, sugerem que a presença de proteínas e gorduras pode modificar o impacto glicêmico dos carboidratos, criando desafios adicionais na predição do IG [30]. Portanto, é fundamental desenvolver ferramentas que possam fornecer estimativas rápidas e precisas do IG de bebidas comerciais, permitindo que consumidores façam escolhas informadas para o controle glicêmico. A análise do índice glicêmico (IG) em matrizes líquidas apresenta uma complexidade maior do que em alimentos sólidos devido à variabilidade na composição e concentração dos carboidratos presentes nas bebidas. Estudos indicam que, em bebidas, a taxa de absorção de açúcares pode ser influenciada por diversos fatores, como a presença de outros componentes macronutrientes, a acidez e a viscosidade do líquido. Essa complexidade demanda o uso de técnicas avançadas de análise, como cromatografia líquida de alta performance (HPLC) e eletroforese capilar, as quais são capazes de identificar e quantificar açúcares individuais, oferecendo uma análise precisa

das concentrações de glicose, frutose e sacarose em diferentes tipos de bebidas [40], [41]. Tais metodologias, embora precisas, enfrentam limitações práticas: são caras, requerem equipamentos especializados e habilidades laboratoriais, o que inviabiliza sua aplicação em larga escala e acessibilidade direta ao consumidor [42]. Dessa forma, o desenvolvimento de novas ferramentas que permitam uma estimativa confiável e rápida do IG em bebidas comerciais é crucial para que indivíduos com necessidades específicas de controle glicêmico possam tomar decisões informadas sobre seu consumo. Além disso, a disponibilização de dados mais acessíveis e precisos sobre o IG de bebidas poderia ter implicações positivas para a saúde pública, ao promover escolhas alimentares mais saudáveis e apoiar iniciativas voltadas à prevenção de doenças crônicas, como diabetes e obesidade [43].

E. Avanços no Uso de Deep Learning para Estimativos de IG

Os avanços destacados no uso de deep learning para predição de glicemia neste artigo incluem a utilização de redes neurais recorrentes (RNNs) bidirecionais com mecanismo de atenção e aprendizagem evidencial para uma predição de glicose personalizada e precisa. A combinação de RNNs com meta-aprendizagem adaptativa e aprendizado evidencial é particularmente significativa, pois permite gerar previsões confiáveis e adaptar rapidamente os modelos a novos dados com precisão melhorada [34], [35]. Além disso, o artigo introduz a "Fast-adaptive and Confident Neural Network" (FCNN), que, ao utilizar redes RNN com meta aprendizagem agnóstica, reduz a necessidade de grandes volumes de dados iniciais para adaptar o modelo a pacientes individuais [36]. Esse avanço é crucial para aplicações móveis, como aplicativos de monitoramento glicêmico em tempo real. A integração de camadas de atenção e uma camada de saída evidencial melhora a capacidade do modelo de focar em dados críticos e de atribuir um nível de confiança a cada previsão, ajudando na mitigação de eventos adversos em contexto clínico [33], [34].

F. Frameworks e Técnicas de Processamento de Imagem para Predição Glicêmica

O uso de deep learning tem revolucionado a análise e predição do índice glicêmico (IG) em alimentos, com abordagens inovadoras baseadas em visão computacional e redes neurais convolucionais (CNNs). Estudos recentes, como o de Khan et al., exploram CNNs para identificar e classificar alimentos, alcançando até 98,22% de acurácia em frutas e 84,30% em alimentos variados [31]. Esses modelos, que dispensam pré-processamento extensivo, são altamente escaláveis, facilitando sua integração em aplicativos móveis para monitoramento de glicemia e consumo de carboidratos. Pesquisas como as de Muresan e Oltean aprimoraram o uso de imagens RGB, grayscale e HSV, alcançando 97,04% de acurácia na classificação de frutas, um avanço importante para aplicações práticas de estimativa de IG [32]. Modelos como LSTM e redes com atenção aplicadas à predição de glicose demonstram a robustez das arquiteturas de deep learning ao capturar padrões temporais e fornecer previsões confiáveis [33]. Além disso, o uso

de redes com meta-aprendizagem e evidências deep learning permite adaptação rápida a novos usuários e maior precisão, ampliando as possibilidades de personalização e aplicação em tempo real para controle glicêmico [34].

REFERENCES

- [1] S. V. Edelman, "Importance of glucose control", *Medical Clinics of North America*, vol. 82, no. 4, pp. 665–687, 1998.
- [2] I. Conget and M. Giménez, "Glucose control and cardiovascular disease—Is it important? No", *Diabetes Care*, vol. 32, suppl. 2, p. S335, 2009.
- [3] World Health Organization, "Diabetes", *World Health Organization*, 2023. [Online]. Available: <https://www.who.int/news-room/fact-sheets/detail/diabetes>. [Accessed: Oct. 21, 2024].
- [4] D. J. A. Jenkins and T. M. S. Wolever and R. H. Taylor and H. Barker and H. Fielden and J. M. Baldwin and D. V. Goff, "Glycemic index of foods: A physiological basis for carbohydrate exchange", *The American Journal of Clinical Nutrition*, vol. 34, no. 3, pp. 362–366, 1981.
- [5] J. C. Brand-Miller, "Importance of glycemic index in diabetes", *The American Journal of Clinical Nutrition*, vol. 59, no. 3, pp. 747S–752S, 1994. DOI: 10.1093/ajcn/59.3.747S.
- [6] G. Cowburn and L. Stockley, "Consumer understanding and use of nutrition labelling: A systematic review", *Public Health Nutrition*, vol. 8, no. 1, pp. 21–28, 2004. DOI: 10.1079/PHN2005666.
- [7] Statista, "Alcoholic drinks – worldwide", *Statista*, 2024. [Online]. Available: <https://www.statista.com/outlook/cmo/alcoholic-drinks/worldwide#revenue>. [Accessed: Oct. 25, 2024].
- [8] Statista, "Non-alcoholic drinks – worldwide", *Statista*, 2024. [Online]. Available: <https://www.statista.com/outlook/cmo/non-alcoholic-drinks/worldwide>. [Accessed: Oct. 25, 2024].
- [9] M. I. Khan, B. Acharya, and R. K. Chaurasiya, "Automatic Prediction of Glycemic Index Category from Food Images Using Machine Learning Approaches", *Arabian Journal for Science and Engineering*, vol. 47, no. 5, pp. 10823–10846, 2022. DOI: 10.1007/s13369-022-06754-0.
- [10] L. Fang, Q. Li, and J. Ning, "Assessment of community-managed blood glucose control in patients with diabetes mellitus in Shenzhen, China", *Journal of Diabetes*, vol. 16, no. e13573, 2024. DOI: 10.1111/1753-0407.13573
- [11] J. C. Seidell, "Obesity, insulin resistance and diabetes—a worldwide epidemic", *British Journal of Nutrition*, vol. 83, no. S1, pp. S5–S8, 2000. DOI: 10.1017/S000711450000088X.
- [12] D. M. Nathan, for the DCCT/EDIC Research Group, "The Diabetes Control and Complications Trial/Epidemiology of Diabetes Interventions and Complications Study at 30 years: Overview", *Diabetes Care*, vol. 37, no. 1, pp. 9–16, 2014. DOI: 10.2337/dc13-2112.
- [13] DCCT Research Group, "Diabetes Control and Complications Trial (DCCT) update", *Diabetes Care*, vol. 13, no. 4, pp. 427–433, 1990. DOI: 10.2337/diacare.13.4.427.
- [14] P. King, I. Peacock, and R. Donnelly, "The UK Prospective Diabetes Study (UKPDS): Clinical and therapeutic implications for type 2 diabetes", *British Journal of Clinical Pharmacology*, vol. 48, no. 5, pp. 643–648, 1999. DOI: 10.1046/j.1365-2125.1999.00092.x.
- [15] The Diabetes Prevention Program Research Group, "The Diabetes Prevention Program (DPP): Description of lifestyle intervention", *Diabetes Care*, vol. 25, no. 12, pp. 2165–2171, 2002. DOI: 10.2337/diacare.25.12.2165.
- [16] J. Mantas, A. Hasman, and M. S. Househ, Eds., "Artificial Intelligence in Medicine: Knowledge Representation and Transparent Models", *Studies in Health Technology and Informatics*, vol. 287, Springer, 2021. DOI: 10.1007/978-3-030-89011-7.
- [17] F. Sultana, A. Sufian, and P. Dutta, "Advancements in image classification using convolutional neural network", *Proceedings of the 2018 Fourth International Conference on Research in Computational Intelligence and Communication Networks (ICRCICN)*, Kolkata, India, 2018, pp. 122–129. DOI: 10.1109/ICRCICN.2018.8718718.
- [18] The ACCORD Study Group, "Action to Control Cardiovascular Risk in Diabetes (ACCORD) trial: Design and methods", *The American Journal of Cardiology*, vol. 99, no. 12A, pp. 21i–33i, 2007. DOI: 10.1016.
- [19] P. D. Reaven et al., "Intensive glucose-lowering therapy reduces cardiovascular disease events in Veterans Affairs Diabetes Trial participants with lower calcified coronary atherosclerosis", *Diabetes*, vol. 58, no. 11, pp. 2642–2648, 2009. DOI: 10.2337/db09-0618.
- [20] NIDDK, "Prediabetes and Insulin Resistance", *National Institute of Diabetes and Digestive and Kidney Diseases*. [Online]. Available: <https://www.niddk.nih.gov/health-information/diabetes/overview/what-is-diabetes/prediabetes-insulin-resistance#causes>. [Accessed Oct. 30, 2024].
- [21] IDF, "About Type 2 Diabetes", International Diabetes Federation. [Online]. Available: <https://idf.org/about/diabetes/type-2/diabetes/>. [Accessed Oct. 30, 2024].
- [22] IDF, "About Type 1 Diabetes", International Diabetes Federation. [Online]. Available: <https://idf.org/about/diabetes/type-1/diabetes/>. [Accessed Oct. 30, 2024].
- [23] J. Lindström et al., "The Finnish Diabetes Prevention Study (DPS): Lifestyle intervention and 3-year results on diet and physical activity", *Diabetes Care*, vol. 26, no. 12, pp. 3230–3236, Dec. 2003. DOI: 10.2337/diacare.26.12.3230.
- [24] E. B. Hamaker and A. A. Tuncil, "Slowly digestible starch: concept, mechanism, and proposed extended glycemic index," *Critical Reviews in Food Science and Nutrition*, vol. 54, no. 9, pp. 1235–1247, 2014. DOI: 10.1080/10408390903372466.
- [25] P. D. McArdle, D. Mellor, S. Rillstone, and J. Taplin, "The role of carbohydrate in diabetes management," *Practical Diabetes*, vol. 33, no. 7, pp. 237–242, 2016.
- [26] D. H. Bessesen, "The Role of Carbohydrates in Insulin Resistance," *Journal of Nutrition*, vol. 131, no. 10, pp. 2782S–2786S, 2001.
- [27] T. M. S. Wolever and D. J. A. Jenkins, *The Glycemic Index: A Physiological Classification of Dietary Carbohydrate*, Oxford University Press, 2002.
- [28] F. S. Atkinson, K. Foster-Powell, and J. C. Brand-Miller, "International tables of glycemic index and glycemic load values: 2008," *Diabetes Care*, vol. 31, no. 12, pp. 2281–2283, 2008.
- [29] S. A. Ross, K. L. Lamkin, and B. W. Vander Jagt, "Carbohydrate analysis of foods and beverages by capillary electrophoresis and high-performance liquid chromatography," *Journal of Chromatography B*, vol. 792, no. 1, pp. 219–227, 2003. DOI: 10.1016/S1570-0232(03)00377-5.
- [30] A. Rytz, D. Adeline, K.-A. Lê, D. Tan, L. Lamothe, O. Roger, and K. Macé, "Predicting Glycemic Index and Glycemic Load from Macronutrients to Accelerate Development of Foods and Beverages with Lower Glucose Responses," *Nutrients*, vol. 11, no. 5, p. 1172, 2019. DOI: 10.3390/nu11051172.
- [31] M. I. Khan, B. Acharya, and R. K. Chaurasiya, "Automatic Prediction of Glycemic Index Category from Food Images Using Machine Learning Approaches," *Arabian Journal for Science and Engineering*, vol. 47, no. 5, pp. 10823–10846, 2022. DOI: 10.1007/s13369-022-06754-0.
- [32] F. L. Pereira, M. T. F. Andrade, e P. C. Cortez, "Classificação do Índice Glicêmico a partir de Imagens de Alimentos com Redes Neurais Convolucionais," *Anais do XXIV Encontro Nacional de Inteligência Artificial e Computacional (ENIAC)*, pp. 1-10, 2020.
- [33] F. Zhu, Y. Li, Y. Shen, Z. Shen, and J. Li, "Deep learning for blood glucose level prediction: How well do models generalize across different data sets?" *PLoS ONE*, vol. 16, no. 2, pp. e0245238, 2021. DOI: 10.1371/journal.pone.0245238.

- [34] T. Zhu, K. Li, P. Herrero, e P. Georgiou, "Personalized Blood Glucose Prediction for Type 1 Diabetes Using Evidential Deep Learning and Meta-Learning," *IEEE Transactions on Biomedical Engineering*, vol. 70, no. 1, pp. 193-204, Jan. 2023. DOI: 10.1109/TBME.2022.3187703.
- [35] S. Langerica et al., "Deep Learning-Based Glucose Prediction Models: A Guide for Practitioners and a Curated Dataset for Improved Diabetes Management," *IEEE Open Journal of Engineering in Medicine and Biology*, vol. 5, pp. 467-475, 2024, doi: 10.1109/OJEMB.2024.3365290.
- [36] T. Zhu, K. Li, P. Herrero, e P. Georgiou, "Personalized Blood Glucose Prediction for Type 1 Diabetes Using Evidential Deep Learning and Meta-Learning," *IEEE Transactions on Biomedical Engineering*, vol. 70, no. 1, pp. 193-204, Jan. 2023, doi: 10.1109/TBME.2022.3187703.
- [37] J. Brand-Miller, S. Hayne, P. Petocz, e S. Colagiuri, "Low-Glycemic Index Diets in the Management of Diabetes: A meta-analysis of randomized controlled trials," *Diabetes Care*, vol. 26, no. 8, pp. 2261-2267, 2003.
- [38] D. J. A. Jenkins, T. M. S. Wolever, G. R. Collier, A. Ocana, A. V. Rao, G. Buckley, Y. Lam, A. Mayer, e L. U. Thompson, "Metabolic effects of a low-glycemic-index diet," *American Journal of Clinical Nutrition*, vol. 46, no. 6, pp. 968-975, 1987.
- [39] J. Brand-Miller e A. E. Buyken, "The glycemic index issue," *Current Opinion in Lipidology*, vol. 23, no. 1, pp. 62-67, 2012.
- [40] S. Wolever, "The Glycemic Index in Practice," *American Journal of Clinical Nutrition*, vol. 89, no. 2, pp. 418-420, 2019.
- [41] J. D. Brennan e A. D. Marchini, "Capillary Electrophoresis for Sugars in Beverage Analysis," *Journal of Analytical Methods in Chemistry*, vol. 32, no. 4, pp. 56-62, 2020.
- [42] P. P. Rubino, "Challenges and Opportunities in Glycemic Index Testing," *Food Chemistry*, vol. 285, pp. 232-240, 2021.
- [43] R. T. Thompson e M. J. Smith, "Public Health Impacts of Glycemic Index Awareness," *Journal of Public Health Nutrition*, vol. 27, no. 6, pp. 1090-1098, 2021.